Un corpus anotado de 6,1 millones de tweets del estallido social chileno (octubre de 2019)

Daniel Alcatruz

2026-10-25

Resumen

Se describe un corpus de 6.119.933 publicaciones emitidas por 701.325 cuentas entre el 11 y el 29 de octubre de 2019, recolectado en tiempo real durante el estallido social chileno mediante 49 consultas aplicadas diariamente a la API de búsqueda de Twitter. El conjunto cubre los diecinueve días centrales del ciclo de protesta, desde las evasiones masivas en el Metro de Santiago hasta el cambio de gabinete del 28 de octubre, y conserva material de cuentas hoy eliminadas o suspendidas que la plataforma ya no permite recuperar.

Además de los campos originales, el corpus se entrega con cuatro capas de anotación construidas para este trabajo: la consulta por la que ingresó cada publicación; la comunidad de pertenencia en la red de retweets diaria, detectada con el algoritmo de Leiden; una clasificación de cuentas que incorpora un registro verificado de 171 cargos públicos en ejercicio, triangulado contra la Biblioteca del Congreso Nacional y Wikidata; y un indicador, a nivel de publicación, de ingreso por consulta ambigua.

Esa última anotación responde a una propiedad del corpus que condiciona su uso: seis de las consultas eran hashtags de fecha, de empleo global, que aportan el 15,4 % del material e introducen tres comunidades sin contenido relacionado con Chile. Se documenta su magnitud y se ofrece el indicador para excluirlas. Se incluye una demostración de uso sobre la dinámica temporal de los polos de la conversación.

1. Especificaciones

Tabla 1: Especificaciones del conjunto de datos

Materia	Ciencias sociales computacionales; comunicación política
Materia específica	Protesta social, redes sociales digitales, corpus anotados
Tipo de datos	Tablas (CSV, Parquet), lista de aristas de red, identificadores de publicaciones
Obtención	API de búsqueda de Twitter (v1.1) mediante `rtweet`, 49 consultas, recolección diaria
Formato	Datos derivados, analizados y seudonimizados
Descripción de la recolección	Recolección diaria durante el evento, del 17 al 29 de octubre de 2019, con una consulta por archivo y consolidación posterior con deduplicación por identificador
Fuente	Twitter (hoy X), publicaciones públicas
Ubicación	Chile (cobertura principal); corpus en español (92,73 % de las publicaciones)
Accesibilidad	Código y derivados: `github.com/Alcatruz/estallido-twitter-2019`
Período	11 al 29 de octubre de 2019 (19 días)

2. Valor de los datos

- **Registro irreproducible de un evento histórico.** El corpus fue recolectado mientras ocurría el mayor ciclo de protesta chileno desde 1990. La API de X ya no ofrece acceso retrospectivo a 2019 a ningún precio, de modo que estos datos no pueden volver a obtenerse. La evidencia disponible indica además que solo un tercio de las publicaciones de conjuntos sensibles sigue siendo recuperable («Nonrandom Tweet Mortality and Data Access Restrictions: Compromising the Replication of Sensitive Twitter Studies» 2024), por lo que el corpus preserva contenido de cuentas hoy eliminadas o suspendidas.
- **Cobertura densa y continua de diecinueve días.** El período abarca desde las evasiones previas hasta el cambio de gabinete, con resolución al segundo y sin interrupciones de recolección, lo que permite estudios de dinámica temporal fina —difusión, latencia de amplificación, estudios de evento— que los conjuntos de corte transversal no admiten.
- **Red de retweets reconstruible día a día.** Se entrega la lista de aristas ponderada y la partición en comunidades de cada jornada, lo que habilita el análisis de cómo cambia la estructura de la conversación durante un ciclo de protesta y no solo su composición agregada.
- **Registro verificado de cargos públicos.** Las 171 cuentas de diputados, senadores, ministros, Presidente y presidentes de partido en ejercicio en octubre de 2019 fueron identificadas por triangulación de fuentes oficiales, con la fuente de cada identificación declarada. Trabajos previos sobre Twitter parlamentario chileno no documentan cómo resolvieron esa asignación.
- **Consulta de recolección documentada.** Se publica la lista completa de las 49 consultas con su aporte respectivo al corpus, condición poco frecuente en los conjuntos de protesta disponibles y necesaria para delimitar qué puede inferirse del material.
- **Indicador de calidad incorporado.** Cada publicación lleva una marca de ingreso por consulta ambigua, de modo que quien reutilice el corpus puede excluir el material no relacionado sin tener que diagnosticarlo.

3. Antecedentes

El 18 de octubre de 2019, tras semanas de evasiones masivas en el Metro de Santiago en protesta por el alza de la tarifa, Chile entró en un ciclo de movilización sin precedentes desde el retorno a la democracia. En los días siguientes se decretó estado de emergencia y toque de queda en la Región Metropolitana, se produjo la mayor manifestación registrada en el país y el gobierno reemplazó a ocho ministros.

La conversación digital asociada fue intensa y breve. Su registro depende enteramente de recolecciones realizadas en el momento: las restricciones posteriores de la plataforma impiden reconstruir retrospectivamente lo que se publicó en esas semanas. El conjunto que aquí se describe fue recolectado por el autor entre el 17 y el 29 de octubre de 2019, con una cadencia diaria y una lista de consultas fijada durante los primeros días del episodio.

4. Descripción de los datos

4.1. Volumen y composición

Tabla 2: Composición del corpus por tipo de publicación.

Tipo	n	%
Retweets	5.355.779	87.51
Publicaciones originales	635.898	10.39
Citas	128.256	2.10
Total	6.119.933	100,00

El corpus contiene 6.119.933 publicaciones con identificador único, emitidas por 701.325 cuentas. La distinción entre publicaciones y textos es relevante para definir denominadores: solo 764.154 publicaciones (12,5 %) fueron compuestas por su emisor, y los textos distintos son 755.220. De las 701.325 cuentas, 178.474 escribieron contenido propio; las restantes aparecen exclusivamente amplificando o siendo amplificadas.

Los análisis de difusión deben usar como denominador las 6.119.933 publicaciones, pues cada retweet es un evento de propagación. Los análisis de discurso deben usar los 755.220 textos: de lo contrario, una publicación con 5.000 retweets pondera 5.000 veces.

4.2. Cobertura temporal

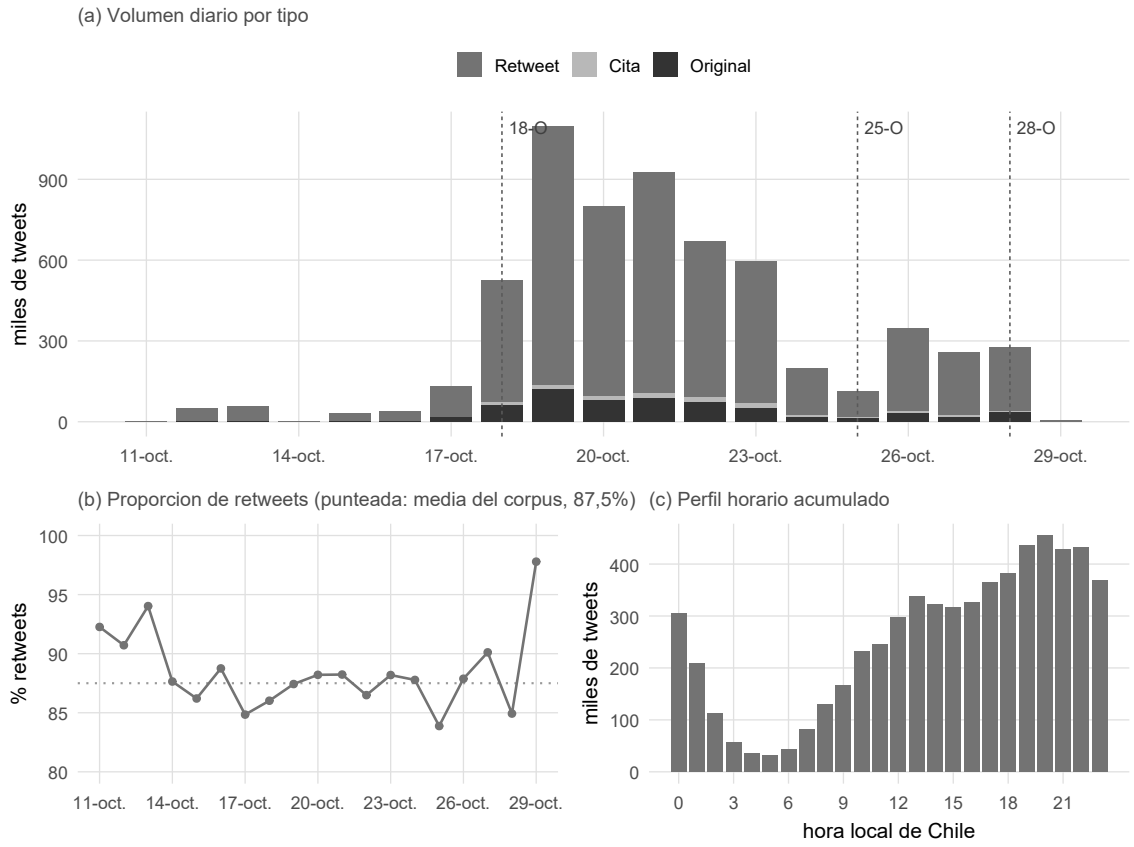


Figura 1: Cobertura temporal del corpus. (a) Volumen diario por tipo de publicación. (b) Proporción de retweets, estable entre 84 % y 90 % pese a que el volumen varía en dos órdenes de magnitud. (c) Perfil horario acumulado en hora local de Chile.

El período cubierto va del 11 al 29 de octubre de 2019. El máximo diario no corresponde al 18 de octubre sino al 19, con 1.096.576 publicaciones. La proporción de retweets permanece entre 83,9 % y

97,8 % durante todo el período, pese a que el volumen diario varía por un factor superior a 300: la estructura de participación no cambia con la intensidad del evento.

4.3. Variables

El conjunto derivado incluye, además de los campos estándar de la API, anotaciones propias: `consulta` (término por el que ingresó cada publicación), `comunidad_18oct`, `clase_cuenta` (política, medio o ciudadana), `es_cargo_publico` y `partido`, `latencia_retweet_min` y `solo_hashtag_fecha` (indicador de contaminación a nivel de publicación).

5. Diseño, materiales y métodos

5.1. Recolección

La recolección se realizó con el paquete `rtweet` sobre la API de búsqueda de Twitter v1.1, con una consulta por archivo y ejecución diaria entre el 17 y el 29 de octubre de 2019. Cada archivo conserva la consulta que lo originó en una columna propia.

Se preservaron 53 archivos correspondientes a 49 consultas distintas, que suman 15.185.311 filas. Una misma publicación puede aparecer en varios archivos cuando satisface más de una consulta; la consolidación deduplica por identificador, de lo que resultan 6.714.876 publicaciones únicas, y aplica un filtro temporal que deja el conjunto final en 6.119.933.

Las consultas combinan hashtags de consigna (`#ChileDesperto`, `#EstoPasaEnChile`), de episodio (`#EvasionMasiva`, `#CambiodeGabinete`), de derechos humanos (`#ChileViolatesHumanRights`), de fecha (`#17oct` a `#22Oct`) y, en menor medida, palabras sueltas (`INDH`, `congreso`, `Saqueos`). La lista completa, con el aporte de cada una, se entrega junto al conjunto.

La lista se fijó durante los primeros días del episodio y no se actualizó después, decisión que tiene consecuencias sobre la cobertura de la segunda semana y que se documenta en la Sección 7.

5.2. Composición del corpus por consulta

Las consultas no aportan en partes iguales. Diez de ellas explican más de la mitad del material y la distribución decae de forma continua: `#ChileDesperto` aporta 658.153 publicaciones y `#HabraConsecuencias`, 61.

Conocer esta distribución importa para el uso: un análisis restringido a los términos de consigna cubre una porción distinta del corpus que uno que incluya los hashtags de fecha, y la 1 muestra que esa diferencia no es solo de volumen sino de contenido.

Verificación de la documentación

Para comprobar que la lista de consultas declarada es completa y consistente con el material efectivamente recolectado se aplicó un contraste independiente: se extrajeron los hashtags de las 6.119.933 publicaciones y se resolvió una cobertura glotona —en cada paso, el hashtag presente en más publicaciones aún no cubiertas— sin consultar la lista declarada. De los cuarenta términos así obtenidos, 37 corresponden a consultas efectivas y explican el 87,9 % del corpus. Los tres restantes son variantes de etiqueta realmente usadas por los participantes frente a la forma registrada en la consulta: `#QueSeVayanLosMilicos` por `#VayanseMilicos` y `#ChadwickAsesino` por la palabra `chadwick`.

El contraste no recupera las consultas formuladas como palabra suelta —`INDH`, `congreso`, `Saqueos`— por estar restringido a hashtags, de modo que confirma la documentación sin sustituirla.

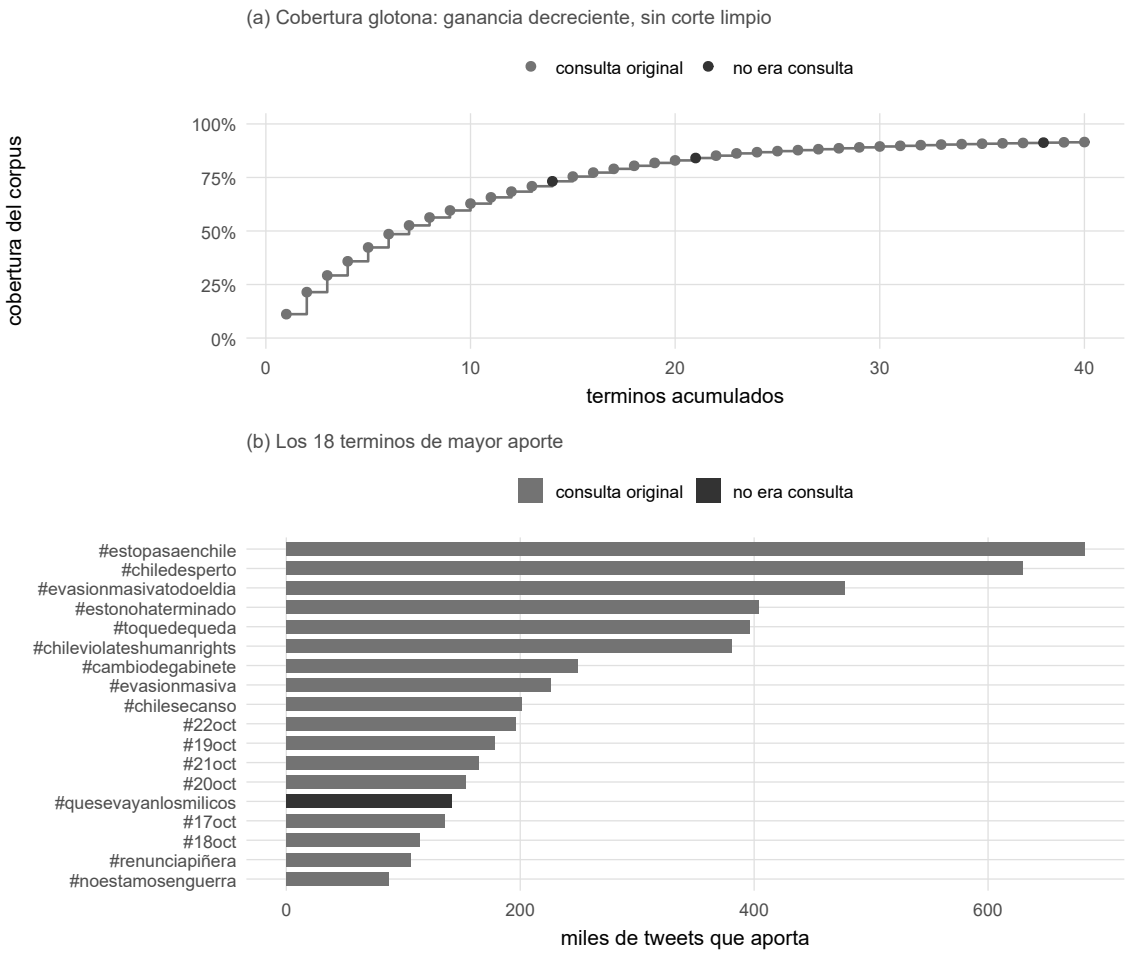


Figura 2: Composición del corpus por término. (a) Cobertura acumulada al añadir términos en orden de aporte. (b) Los dieciocho de mayor contribución individual.

5.3. Índice de contaminación por consulta ambigua

Seis de las consultas son hashtags de fecha y aportan 941.446 publicaciones (15,4 % del corpus). Son términos de uso global: cualquier usuario del mundo puede emplear `#18Oct` ese día para cualquier asunto.

Para medir el efecto se define, sobre las comunidades de la red de retweets del 18 de octubre, la fracción de publicaciones que contiene un hashtag de fecha pero ningún término del vocabulario chileno de la consulta.

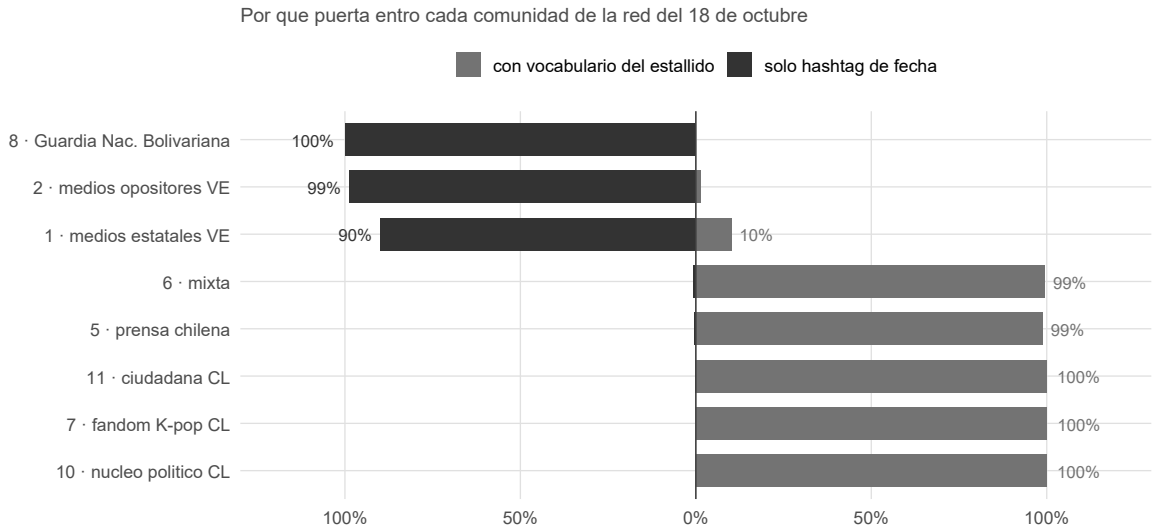


Figura 3: Índice de contaminación. A la derecha, publicaciones con vocabulario del estallido; a la izquierda, publicaciones que solo portan un hashtag de fecha. La separación entre comunidades chilenas y no chilenas es neta.

Tabla 3: Índice de contaminación por comunidad, 18 de octubre de 2019.

Comunidad	Publicaciones	Con término chileno	Solo hashtag de fecha
8 · Guardia Nac. Bolivariana (VE)	3.901	0.0 %	100.0 %
2 · Medios opositores (VE)	41.264	1.3 %	98.7 %
1 · Medios estatales (VE)	60.107	10.1 %	89.9 %
6 · Mixta	11.610	99.4 %	0.6 %
5 · Prensa chilena	14.898	98.8 %	0.5 %
11 · Ciudadana (CL)	19.983	99.9 %	0.1 %
10 · Núcleo político (CL)	186.425	99.9 %	0.0 %
7 · Fandom K-pop (CL)	157.772	100.0 %	0.0 %

La separación es completa: las tres comunidades no chilenas presentan entre 89,9 % y 100 % de publicaciones ingresadas solo por hashtag de fecha, y las cinco chilenas entre 0,0 % y 0,6 %. La comunidad 8 no contiene ninguna publicación con vocabulario del estallido.

Estas comunidades agrupan 10.828 cuentas y 74.130 retweets, el 19,1 % de los nodos de la red. Su penetración en la conversación chilena, sin embargo, es marginal: solo el 1,99 % de sus retweets alcanza cuentas chilenas, y apenas el 0,42 % de los retweets chilenos amplifica cuentas del bloque. Presencia y influencia difieren en dos órdenes de magnitud, lo que advierte contra inferir influencia a partir del volumen.

5.4. Subconjunto recomendado y su validación

El corpus se entrega completo y etiquetado, de modo que admite dos usos. Quien estudie el artefacto de recolección dispone del material íntegro con la marca de ingreso ambiguo; quien investigue el estallido puede restringirse al subconjunto recomendado, definido aquí para que no tenga que fijar el criterio por su cuenta.

La exclusión opera en dos reglas, almacenadas por separado para que puedan aplicarse sueltas:

Tabla 4: Reglas de exclusión y material resultante.

Regla	Publicaciones excluidas	Corpus restante
(a) hashtag de fecha y ningún término chileno	867.656	5.252.277 (85,8 %)
(b) cuenta de las comunidades 1, 2 u 8	938.325	5.181.608 (84,7 %)
ambas (subconjunto recomendado)	1.124.628	4.995.305 (81,6 %)

La validación emplea seis indicadores que **no intervienen** en la regla de exclusión, de modo que el contraste no es circular: país de geolocalización, ubicación declarada en el perfil, idioma, y marcadores léxicos chilenos —`weón`, `cachai`, `po`, `pacos`— y venezolanos.

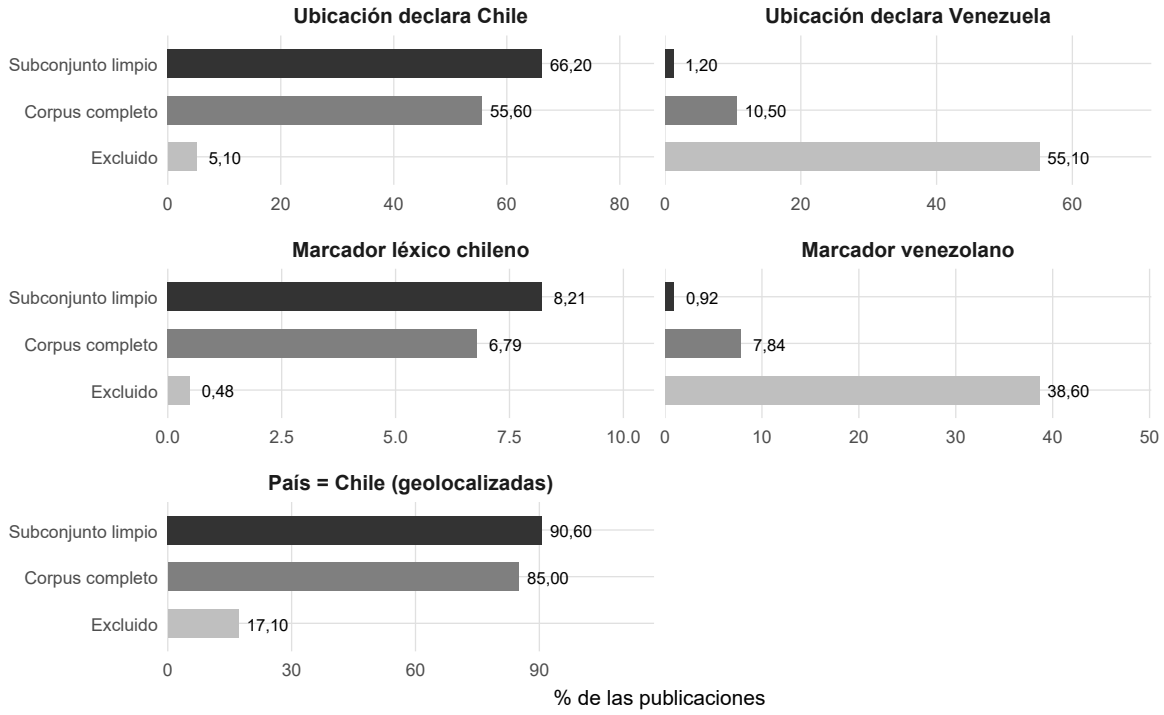


Figura 4: Validación del subconjunto recomendado. Los indicadores son independientes de la regla con que se construyó la exclusión.

Tabla 5: Indicadores de validación del subconjunto recomendado.

conjunto	Corpus completo	Subconjunto limpio	Excluido
País = Chile (geo.)	85.0	90.6	17.1
Ubic. declara Chile	55.6	66.2	5.1
Ubic. declara Venezuela	10.5	1.2	55.1
Marcador chileno	6.79	8.21	0.48
Marcador venezolano	7.84	0.92	38.60

Tabla 5: Indicadores de validación del subconjunto recomendado.

El material excluido resulta 55,1 % venezolano por ubicación declarada y 38,6 % por marcador léxico, frente a 1,2 % y 0,9 % en el subconjunto recomendado. La separación opera en ambos sentidos: lo retirado es mayoritariamente ajeno y lo retenido es más chileno que el corpus de partida.

Sobre-exclusión declarada. La regla (b) retira toda la actividad de esas cuentas, incluida la que sí trata de Chile. Entre el material excluido quedan 66.680 usos de `#toquedequeda` y 50.569 de `#ChileDesperto`, casi todos atribuibles a la comunidad 1 —medios estatales venezolanos que cubrieron el episodio—, cuyo índice de contaminación es 89,9 % y no 100 %. La decisión de tratar esa cobertura como ajena a la conversación chilena es interpretativa, no técnica; quien sostenga que forma parte del fenómeno puede aplicar únicamente la regla (a).

5.5. Estructura de la red y clases de cuenta

Con los retweets del 18 de octubre se construye una red dirigida de 110.736 nodos y 407.387 aristas ponderadas. Tras conservar el núcleo de k-core ≥ 2 y la componente gigante, la red queda en 56.724 nodos y 354.123 aristas. La detección de comunidades con el algoritmo de Leiden (Traag, Waltman, y Eck 2019) arroja 143 comunidades con modularidad 0,505; el 78,6 % de los retweets ocurre dentro de la propia comunidad.

Las cuentas se clasifican en tres clases. La clase *política* procede de un registro de 171 cargos en ejercicio en octubre de 2019, construido por triangulación de las reseñas biográficas de la Biblioteca del Congreso Nacional, Wikidata y emparejamiento por nombre validado contra la biografía.

Tabla 6: Participación de cada clase de cuenta en el corpus.

Clase	Cuentas	% cuentas	% publicaciones	% retweets	RT por cuenta
ciudadana	672.258	95.75	95.35	78.75	6,3
medio	29.720	4.23	4.63	19.02	34,3
politica	125	0.02	0.02	2.23	955,9

Una cuenta de cargo público recibe en promedio 956 retweets y una ciudadana 6, una razón de 152 a 1. Sin embargo, la clase política concentra apenas el 2,23 % de la amplificación total: de las quince cuentas más retuiteadas del corpus, una sola corresponde a un cargo electo. La asimetría se explica por el rendimiento y no por el volumen: la clase política produce 451 textos únicos en 19 días, cada uno de los cuales circula 265,9 veces, frente a 7,3 de un texto ciudadano.

6. Demostración de uso: dinámica temporal de los polos

Para ilustrar qué tipo de preguntas admiten las anotaciones entregadas, se presenta un análisis sobre una de ellas: si existió una contraparte progobierno en la conversación y en qué momento dejó de existir. Se mide por tres vías independientes.

La primera es léxica. Se definen dos repertorios de consigna a partir de hashtags verificados en el corpus —progobierno: `#YoApoyoAlPresidente`, `#CondenamosLaDelincuencia`, `#PazParaChile`; antigobierno: `#RenunciaPiñera`, `#PiñeraDictador`, `#QueSeVayanLosMilicos`, `#ChileViolatesHumanRights`, entre otros— y se calculan tasas diarias por 10.000 publicaciones, lo que neutraliza la enorme variación de volumen entre días. Se excluye del índice `#ChileSomosTodos`, pese a sus 136.888 apariciones, por haber sido empleado por ambas partes como consigna de unidad; asignarlo a un polo sería arbitrario.

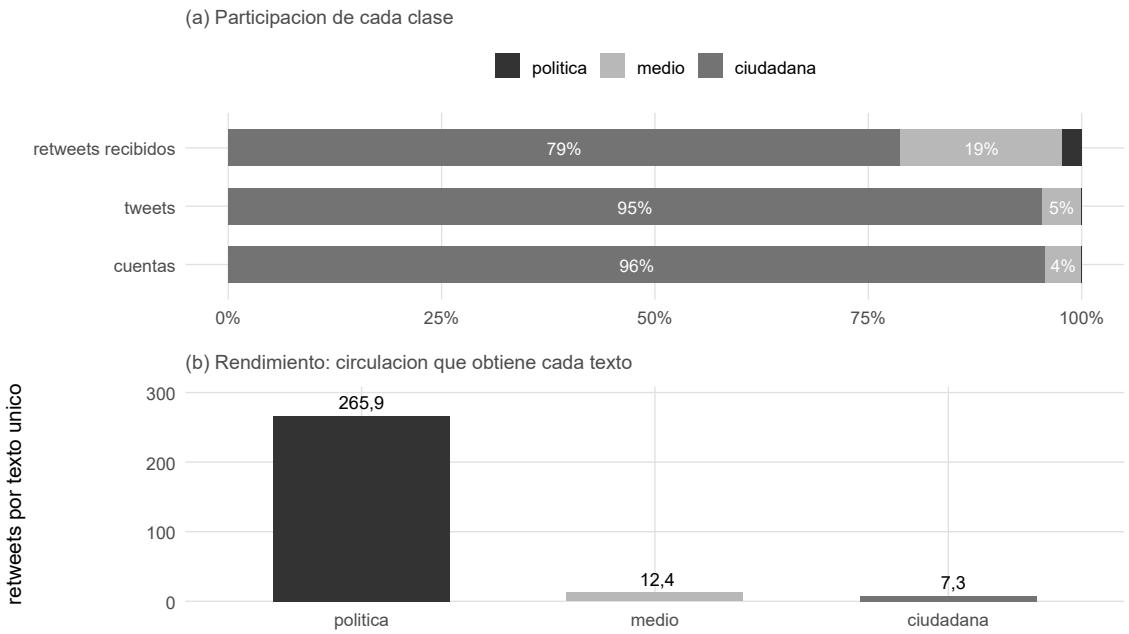


Figura 5: Clases de cuenta. (a) Participación de cada clase en cuentas, publicaciones y retweets recibidos. (b) Circulación obtenida por cada texto único.

La segunda es de actores: cuentas del registro de cargos de cada coalición que aparecen cada día, publicando o siendo amplificadas.

La tercera es estructural. Se reconstruye la red de retweets de cada uno de los 16 días con volumen suficiente, se detectan comunidades y se clasifica cada comunidad según la composición de polo del contenido que escriben sus miembros. Se considera progobierno a toda comunidad que emita al menos 30 consignas y en la que más de la mitad correspondan a ese repertorio.

Tabla 7: Presencia estructural del polo progobierno, por día. Las consignas se expresan por cada 10.000 publicaciones; la columna de red, en porcentaje de nodos.

Día	Nodos	Comun. progob.	Red progob.	Consigna progob.	Consigna antigob.	Modularidad
12-oct.	7.218	1	20.66	10.6	0.6	0.498
17-oct.	14.864	0	0.00	0.1	10.7	0.706
18-oct.	56.724	0	0.00	0.1	76.8	0.504
19-oct.	107.293	0	0.00	26.0	799.3	0.453
20-oct.	90.994	2	18.62	71.3	1258.3	0.525
21-oct.	100.778	1	6.13	201.8	3613.6	0.494
23-oct.	68.899	0	0.00	15.0	6454.4	0.423
26-oct.	40.859	0	0.00	2.1	1083.8	0.356
28-oct.	36.372	0	0.00	2.5	463.7	0.374

El polo progobierno desaparece dos veces. El 12 de octubre, antes del estallido, constituía el 20,7 % de la red y sus consignas superaban a las opositoras. Entre el 13 y el 19 de octubre deja de existir como estructura: ninguna comunidad progobierno en siete días consecutivos. Reaparece el 20 y el 21 —durante el estado de emergencia y los saqueos— alcanzando el 18,6 % de la red y su máximo absoluto de consignas, y desde el 22 de octubre no vuelve a formar comunidad en ningún día.

En el conjunto del corpus las consignas progobierno suman 31.431 publicaciones (0,51 %) frente a

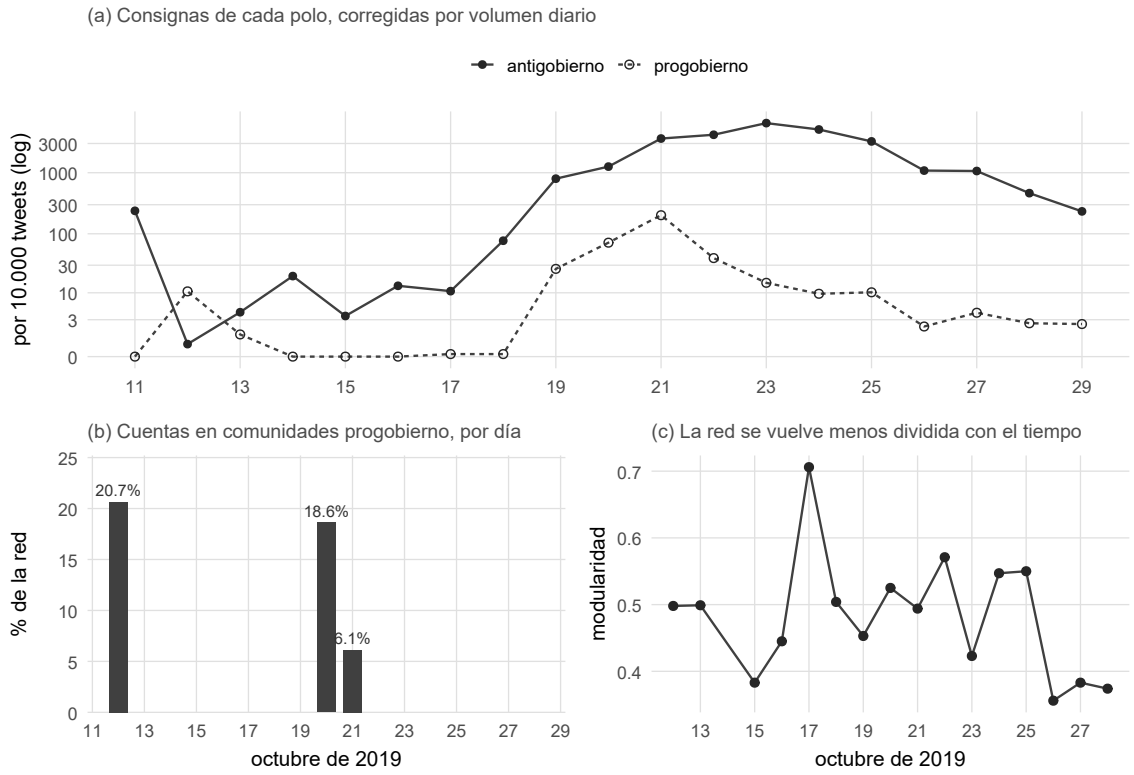


Figura 6: Dinámica de los polos. (a) Tasas diarias de consigna por cada 10.000 publicaciones, en escala logarítmica. (b) Porcentaje de la red diaria en comunidades progobierno. (c) Modularidad de la red diaria.

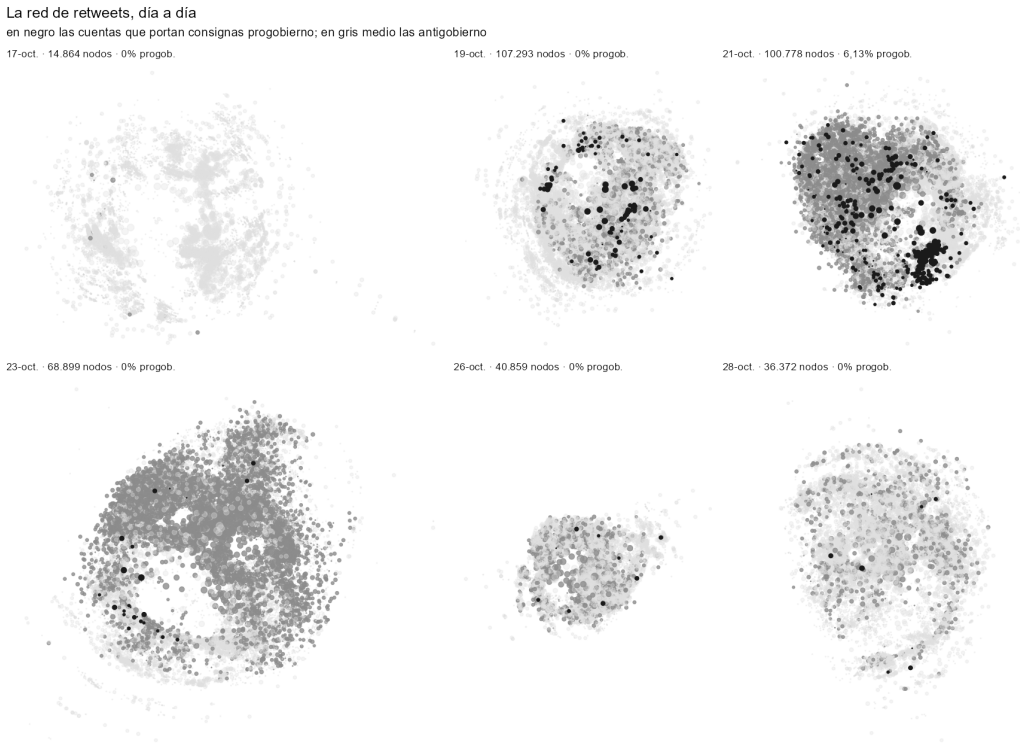


Figura 7: Red de retweets de seis días. En negro las cuentas que portan consignas progobierno; en gris medio las antigobierno; en gris claro el resto. El 21 de octubre la comunidad progobierno es visible como cúmulo; desde el 23 solo quedan cuentas dispersas.

1.405.307 antigobierno (22,96 %).

Un resultado colateral merece atención: la modularidad de la red diaria decrece de forma sostenida, de 0,706 el 17 de octubre a valores entre 0,356 y 0,383 en los últimos días. La red se vuelve *menos* dividida conforme avanza el ciclo, lo que sugiere un funcionamiento unificador y no polarizante del episodio, al menos dentro de lo que este corpus captura.

Este resultado debe leerse con una advertencia: la clasificación es léxica y no ideológica. Una cuenta que cite una consigna progobierno para ridiculizarla queda contabilizada en ese polo, y con 31.431 publicaciones en total un sesgo de ese tipo no es despreciable.

7. Limitaciones

1. **Bordes truncados.** El 11 y el 29 de octubre contienen 168 y 4.203 publicaciones respectivamente, por el corte de la ventana de recolección. Deben excluirse de cualquier serie diaria.
2. **Sesgo hacia el vocabulario inicial.** La lista de consultas se fijó durante la primera semana. El 25 de octubre, día de la mayor manifestación del ciclo, registra 112.812 publicaciones, menos que la víspera. La consulta `#MarchaDelMillon` aporta 48.558 publicaciones frente a las 603.398 de `#ChileDesperto`. El corpus subrepresenta sistemáticamente la segunda semana.
3. **Contaminación por consulta ambigua.** Cuantificada en la
    1. Se recomienda excluir las comunidades 1, 2 y 8 de todo análisis sustantivo sobre el estallido.
4. **La clase *medio* es heurística.** A diferencia de la clase política, que procede de un registro, se detecta por vocabulario y presenta errores en ambas direcciones. Debe usarse como filtro y no como censo.
5. **La clasificación de polos es léxica, no ideológica.** Véase la
    2.
6. **Perfil léxico de la clase política no interpretable.** Con 451 textos únicos, las medidas de especificidad quedan dominadas por un puñado de publicaciones virales.
7. **Cobertura incompleta del padrón.** Se identifican 135 de 156 diputados en ejercicio (86,5 %) y 6 de 16 ministros.

8. Declaración ética

El corpus contiene publicaciones que eran públicas al momento de su emisión. Se aplica seudonimización diferenciada: las cuentas de cargos públicos conservan su identificador, por tratarse de actuación pública de figuras públicas y porque su trazabilidad es condición del valor analítico; las restantes se sustituyen por un resumen criptográfico estable con sal. La antigüedad de cuenta se publica en años y el número de seguidores en órdenes de magnitud, pues su combinación exacta permite la reidentificación.

Se reconoce una tensión irresoluble: el valor archivístico del corpus proviene de preservar material que ya no existe en la plataforma, y esa misma propiedad constituye el problema de privacidad, en particular respecto de usuarios que eliminaron sus cuentas con posterioridad. La distinción por condición de figura pública administra esa tensión sin eliminarla.

La redistribución se ajusta a las restricciones de la plataforma, que limitan la difusión de contenido a identificadores (Golland et al. 2026). Se publican abiertamente los identificadores y los derivados que no constituyen contenido; el texto de cuentas ciudadanas queda disponible bajo solicitud.

9. Disponibilidad de los datos

Código y datos derivados: `https://github.com/Alcatruz/estallido-twitter-2019`. Depósito con identificador persistente en preparación.

Agradecimientos

El procesamiento utilizó `data.table` (Dowle y Srinivasan 2023), `igraph` (Csardi y Nepusz 2006) y `arrow`.

Csardi, Gabor, y Tamas Nepusz. 2006. «The igraph software package for complex network research». *InterJournal, Complex Systems* 1695 (5): 1-9.

Dowle, Matt, y Arun Srinivasan. 2023. *data.table: Extension of 'data.frame'*.

Golland, Alexander, Oliver Watteler, Jonas Recker, Jan Schwalbach, y Libby Bishop. 2026. «From (almost) open to heavily restricted data access: The development of the Twitter/X developer policies». *Big Data & Society*. https://doi.org/10.1177/20539517261419333.

«Nonrandom Tweet Mortality and Data Access Restrictions: Compromising the Replication of Sensitive Twitter Studies». 2024. *Political Analysis*.

Traag, Vincent A., Ludo Waltman, y Nees Jan van Eck. 2019. «From Louvain to Leiden: guaranteeing well-connected communities». *Scientific Reports* 9 (1): 5233. https://doi.org/10.1038/s41598-019-41695-z.