Un corpus de 6,1 millones de tweets del estallido social chileno (octubre de 2019), con la consulta de recolección reconstruida y un diagnóstico de contaminación

Daniel Alcatruz

2026-10-24

Resumen

Se presenta un corpus de 6.119.933 tweets publicados por 701.325 cuentas entre el 11 y el 29 de octubre de 2019, recolectado en tiempo real durante el estallido social chileno mediante 49 consultas aplicadas a la API de búsqueda de Twitter. El corpus no conservaba documentación de su consulta de origen, condición habitual en los conjuntos de datos de redes sociales compartidos. Se describe un procedimiento para reconstruir esa consulta únicamente desde los datos, mediante cobertura glotona sobre los hashtags observados, y se lo valida contra los archivos originales de recolección, recuperados con posterioridad: 37 de 40 términos reconstruidos corresponden a consultas efectivas y explican el 87,9 % del corpus. La reconstrucción revela que seis de las consultas eran hashtags de fecha, que aportan el 15,4 % del material y constituyen una vía de entrada de contenido ajeno al objeto de estudio. Se propone un índice de contaminación por comunidad que separa de forma neta a las comunidades que ingresaron por esa vía. El conjunto se acompaña de un registro de 171 cuentas de cargos públicos en ejercicio, construido por triangulación de fuentes oficiales, y de datos derivados que no constituyen contenido redistribuible.

1. Especificaciones

Tabla 1: Especificaciones del conjunto de datos

Materia	Ciencias sociales computacionales; comunicación política
Materia específica	Protesta social, redes sociales digitales, procedencia de datos
Tipo de datos	Tablas (CSV, Parquet), lista de aristas de red, identificadores de publicaciones
Obtención	API de búsqueda de Twitter (v1.1) mediante `rtweet`, 49 consultas, recolección diaria
Formato	Datos derivados, analizados y seudonimizados
Descripción de la recolección	Recolección diaria durante el evento, del 17 al 29 de octubre de 2019, con una consulta por archivo y consolidación posterior con deduplicación por identificador
Fuente	Twitter (hoy X), publicaciones públicas
Ubicación	Chile (cobertura principal); corpus en español (92,73 % de las publicaciones)
Accesibilidad	Código y derivados: `github.com/Alcatruz/estallido-twitter-2019`
Período	11 al 29 de octubre de 2019 (19 días)

2. Valor de los datos

- **Registro irreproducible de un evento histórico.** El corpus fue recolectado mientras ocurría el mayor ciclo de protesta chileno desde 1990. La API de X ya no ofrece acceso retrospectivo a 2019 a ningún precio, de modo que estos datos no pueden volver a obtenerse. La evidencia

disponible indica además que solo un tercio de las publicaciones de conjuntos sensibles sigue siendo recuperable («Nonrandom Tweet Mortality and Data Access Restrictions: Compromising the Replication of Sensitive Twitter Studies» 2024), por lo que el corpus preserva material eliminado o suspendido con posterioridad.

- **Procedencia documentada, incluida la consulta.** A diferencia de la mayoría de los corpus de protesta disponibles, aquí se publica la lista completa de las 49 consultas con que se recolectó, recuperada de los archivos originales. Esto permite saber qué puede y qué no puede inferirse del material.
- **Un método reutilizable para corpus sin procedencia.** El procedimiento de reconstrucción de consultas descrito en la Sección 5.2 es aplicable a cualquier conjunto recolectado por términos cuya consulta se haya perdido, y aquí se reporta su desempeño validado contra la consulta real.
- **Un diagnóstico de contaminación que no existía.** El índice de la 1 cuantifica qué fracción de un corpus ingresó por términos ambiguos. Dado que los hashtags de fecha son práctica habitual en la recolección de datos de protesta, el problema que mide es general.
- **Capas de anotación ausentes en otros corpus del período**: comunidad en la red de retweets, clase de cuenta, registro verificado de cargos públicos, latencia de amplificación e indicador de contaminación por publicación.

3. Antecedentes

El 18 de octubre de 2019, tras semanas de evasiones masivas en el Metro de Santiago en protesta por el alza de la tarifa, Chile entró en un ciclo de movilización sin precedentes desde el retorno a la democracia. La conversación digital asociada fue intensa y breve, y su registro depende de recolecciones hechas en el momento.

El conjunto que aquí se describe fue recolectado por el autor entre el 17 y el 29 de octubre de 2019, sin un diseño de investigación previo, bajo la expectativa de que el episodio resultaría relevante. Esa circunstancia —común en la recolección de datos de crisis— explica que el conjunto careciera inicialmente de documentación sobre su propia consulta, y motivó el procedimiento de reconstrucción que constituye el aporte metodológico de este trabajo.

4. Descripción de los datos

4.1. Volumen y composición

Tabla 2: Composición del corpus por tipo de publicación.

Tipo	n	%
Retweets	5.355.779	87.51
Publicaciones originales	635.898	10.39
Citas	128.256	2.10
Total	6.119.933	100,00

El corpus contiene 6.119.933 publicaciones con identificador único, emitidas por 701.325 cuentas. La distinción entre publicaciones y textos es relevante para definir denominadores: solo 764.154 publicaciones (12,5 %) fueron compuestas por su emisor, y los textos distintos son 755.220. De las 701.325 cuentas, 178.474 escribieron contenido propio; las restantes aparecen exclusivamente amplificando o siendo amplificadas.

Los análisis de difusión deben usar como denominador las 6.119.933 publicaciones, pues cada retweet es un evento de propagación. Los análisis de discurso deben usar los 755.220 textos: de lo contrario, una publicación con 5.000 retweets pondera 5.000 veces.

4.2. Cobertura temporal

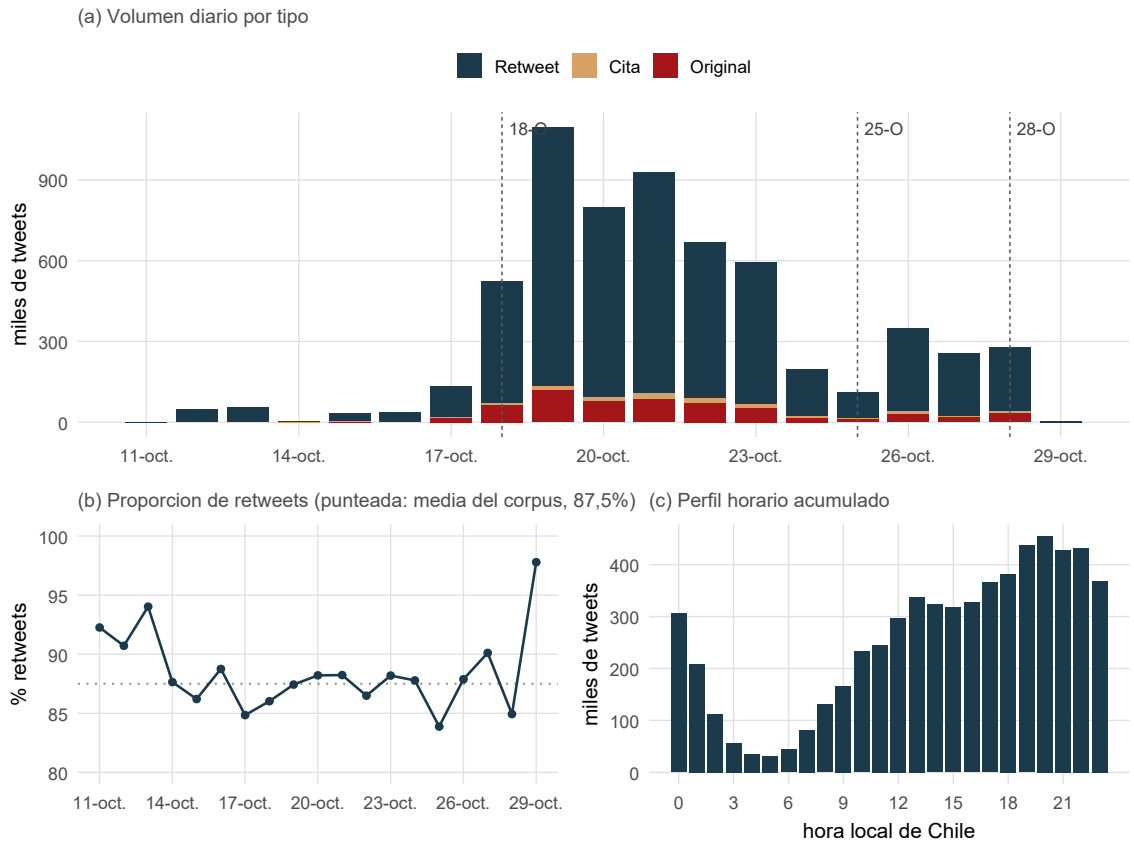


Figura 1: Cobertura temporal del corpus. (a) Volumen diario por tipo de publicación. (b) Proporción de retweets, estable entre 84 % y 90 % pese a que el volumen varía en dos órdenes de magnitud. (c) Perfil horario acumulado en hora local de Chile.

El período cubierto va del 11 al 29 de octubre de 2019. El máximo diario no corresponde al 18 de octubre sino al 19, con 1.096.576 publicaciones. La proporción de retweets permanece entre 83,9 % y 97,8 % durante todo el período, pese a que el volumen diario varía por un factor superior a 300: la estructura de participación no cambia con la intensidad del evento.

4.3. Variables

El conjunto derivado incluye, además de los campos estándar de la API, anotaciones propias: `consulta` (término por el que ingresó cada publicación), `comunidad_18oct`, `clase_cuenta` (política, medio o ciudadana), `es_cargo_publico` y `partido`, `latencia_retweet_min` y `solo_hashtag_fecha` (indicador de contaminación a nivel de publicación).

5. Diseño, materiales y métodos

5.1. Recolección

La recolección se realizó con `rtweet` sobre la API de búsqueda de Twitter v1.1, con una consulta por archivo y ejecución diaria entre el 17 y el 29 de octubre de 2019. Se preservaron 53 archivos correspondientes a 49 consultas distintas, que suman 15.185.311 filas. La consolidación deduplica por identificador, de lo que resultan 6.714.876 publicaciones únicas, y aplica un filtro temporal adicional que deja el conjunto final en 6.119.933.

Las consultas combinan hashtags de consigna (`#ChileDesperto`, `#EstoPasaEnChile`), de episodio (`#EvasionMasiva`, `#CambiodeGabinete`), de derechos humanos (`#ChileViolatesHumanRights`), de fecha (`#17oct` a `#22Oct`) y, en menor medida, palabras sueltas (`INDH`, `congreso`, `Saqueos`).

5.2. Reconstrucción de la consulta

El archivo consolidado no conservaba la columna de consulta. Dado que un corpus recolectado por términos debe contener al menos uno de ellos en casi toda publicación, se extraen los hashtags de los 6.119.933 textos y se resuelve una cobertura glotona: en cada paso se selecciona el hashtag presente en más publicaciones aún no cubiertas.

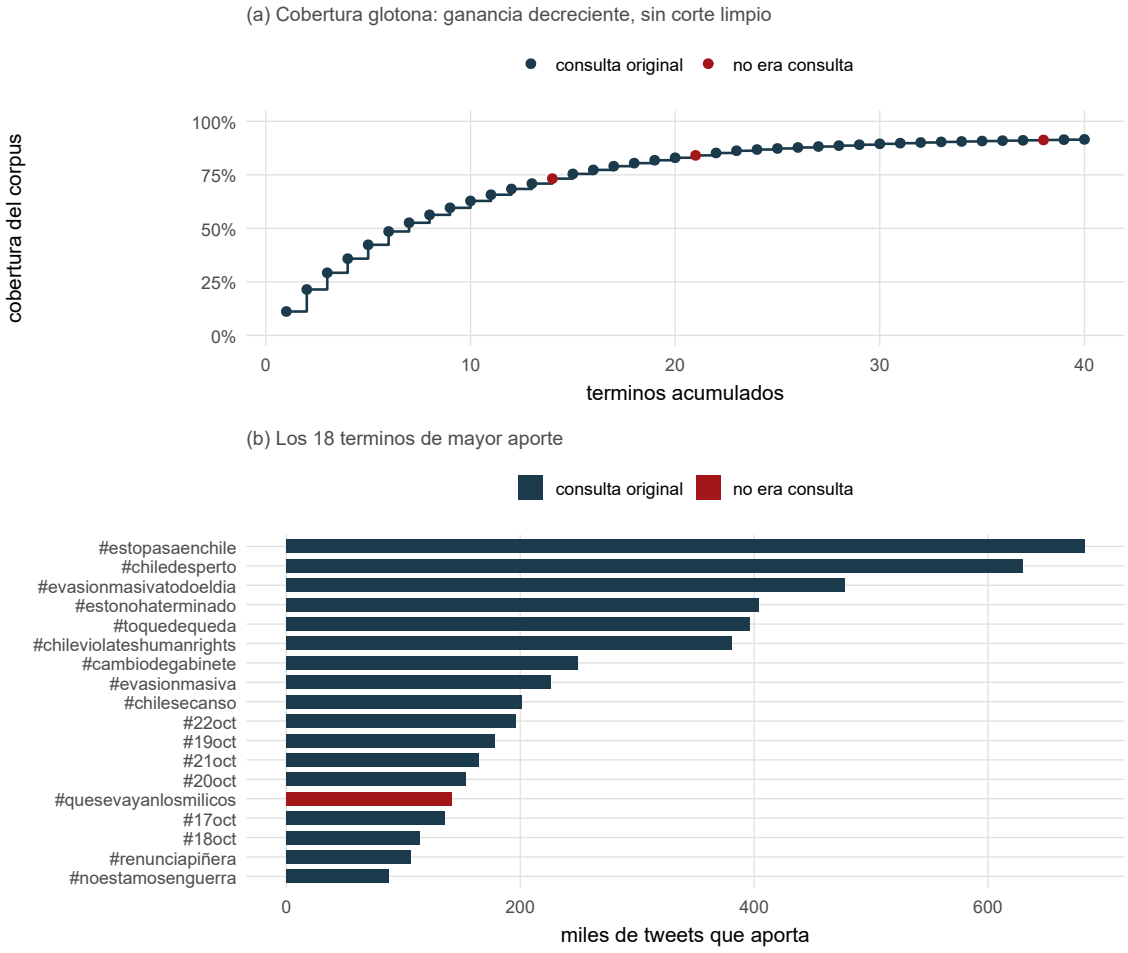


Figura 2: Reconstrucción de la consulta. (a) Cobertura acumulada: la ganancia marginal decrece de forma continua, sin un corte que separe términos de consulta de vocabulario emergente. (b) Los 18 términos de mayor aporte, coloreados según si corresponden a una consulta efectiva.

Cuarenta términos cubren el 91,5 % del corpus. La ausencia de un salto marcado en la ganancia

marginal —de 11,2 % el primer término a 0,1 % el cuadragésimo— es en sí informativa: indica una lista de rastreo extensa y no un rastreo de dos o tres etiquetas.

5.3. Validación

La recuperación posterior de los archivos originales permitió contrastar la reconstrucción contra la consulta efectiva.

Tabla 3: Desempeño de la reconstrucción contra la consulta real.

Indicador	Valor
Términos reconstruidos	40
Corresponden a una consulta efectiva	37 (92 %)
Cobertura del corpus que explican los aciertos	87,9 %
Consultas originales no recuperadas	18 de 49

Los tres términos reconstruidos que no corresponden a una consulta son casi aciertos: el procedimiento identificó `#QueSeVayanLosMilicos` y `#ChadwickAsesino`, mientras que las consultas fueron `#VayanseMilicos` y la palabra `chadwick`. En esos casos la reconstrucción describe mejor el contenido efectivo del corpus que la consulta que lo originó.

La limitación del método es simétrica y cuantificable: de las 49 consultas originales, 18 no se recuperan, y corresponden mayoritariamente a consultas por palabra suelta. Un procedimiento basado en hashtags es por construcción ciego a ellas.

5.4. Índice de contaminación por consulta ambigua

Seis de las consultas son hashtags de fecha y aportan 941.446 publicaciones (15,4 % del corpus). Son términos de uso global: cualquier usuario del mundo puede emplear `#18Oct` ese día para cualquier asunto.

Para medir el efecto se define, sobre las comunidades de la red de retweets del 18 de octubre, la fracción de publicaciones que contiene un hashtag de fecha pero ningún término del vocabulario chileno de la consulta.

Tabla 4: Índice de contaminación por comunidad, 18 de octubre de 2019.

Comunidad	Publicaciones	Con término chileno	Solo hashtag de fecha
8 · Guardia Nac. Bolivariana (VE)	3.901	0.0 %	100.0 %
2 · Medios opositores (VE)	41.264	1.3 %	98.7 %
1 · Medios estatales (VE)	60.107	10.1 %	89.9 %
6 · Mixta	11.610	99.4 %	0.6 %
5 · Prensa chilena	14.898	98.8 %	0.5 %
11 · Ciudadana (CL)	19.983	99.9 %	0.1 %
10 · Núcleo político (CL)	186.425	99.9 %	0.0 %
7 · Fandom K-pop (CL)	157.772	100.0 %	0.0 %

La separación es completa: las tres comunidades no chilenas presentan entre 89,9 % y 100 % de publicaciones ingresadas solo por hashtag de fecha, y las cinco chilenas entre 0,0 % y 0,6 %. La comunidad 8 no contiene ninguna publicación con vocabulario del estallido.

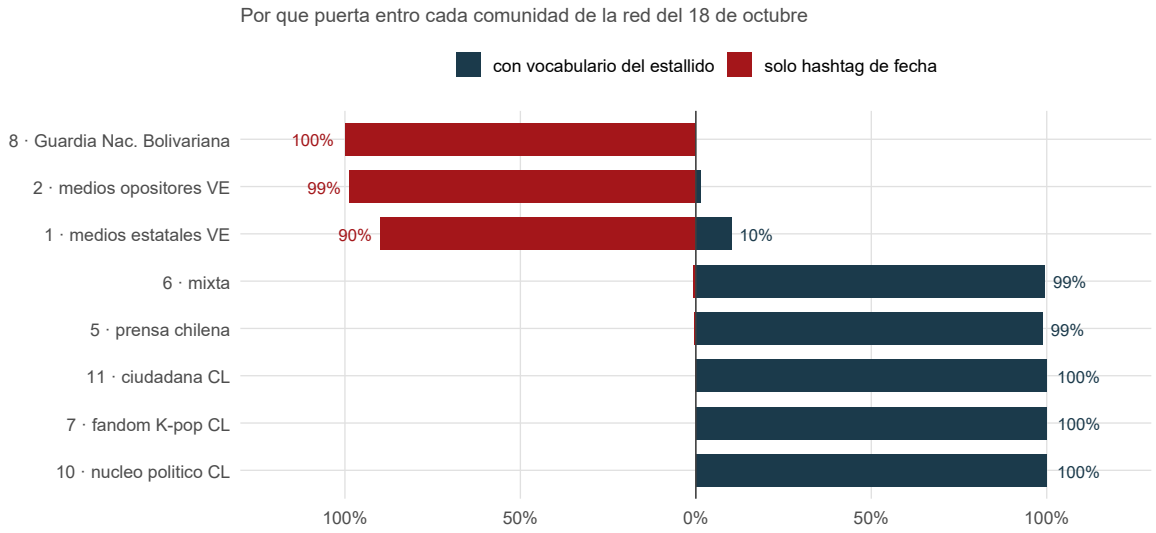


Figura 3: Índice de contaminación. A la derecha, publicaciones con vocabulario del estallido; a la izquierda, publicaciones que solo portan un hashtag de fecha. La separación entre comunidades chilenas y no chilenas es neta.

Estas comunidades agrupan 10.828 cuentas y 74.130 retweets, el 19,1 % de los nodos de la red. Su penetración en la conversación chilena, sin embargo, es marginal: solo el 1,99 % de sus retweets alcanza cuentas chilenas, y apenas el 0,42 % de los retweets chilenos amplifica cuentas del bloque. Presencia y influencia difieren en dos órdenes de magnitud, lo que advierte contra inferir influencia a partir del volumen.

5.5. Estructura de la red y clases de cuenta

Con los retweets del 18 de octubre se construye una red dirigida de 110.736 nodos y 407.387 aristas ponderadas. Tras conservar el núcleo de k-core ≥ 2 y la componente gigante, la red queda en 56.724 nodos y 354.123 aristas. La detección de comunidades con el algoritmo de Leiden (Traag, Waltman, y Eck 2019) arroja 143 comunidades con modularidad 0,505; el 78,6 % de los retweets ocurre dentro de la propia comunidad.

Las cuentas se clasifican en tres clases. La clase *política* procede de un registro de 171 cargos en ejercicio en octubre de 2019, construido por triangulación de las reseñas biográficas de la Biblioteca del Congreso Nacional, Wikidata y emparejamiento por nombre validado contra la biografía.

Tabla 5: Participación de cada clase de cuenta en el corpus.

Clase	Cuentas	% cuentas	% publicaciones	% retweets	RT por cuenta
ciudadana	672.258	95.75	95.35	78.75	6,3
medio	29.720	4.23	4.63	19.02	34,3
politica	125	0.02	0.02	2.23	955,9

Una cuenta de cargo público recibe en promedio 956 retweets y una ciudadana 6, una razón de 152 a 1. Sin embargo, la clase política concentra apenas el 2,23 % de la amplificación total: de las quince cuentas más retuiteadas del corpus, una sola corresponde a un cargo electo. La asimetría se explica por el rendimiento y no por el volumen: la clase política produce 451 textos únicos en 19 días, cada uno de los cuales circula 265,9 veces, frente a 7,3 de un texto ciudadano.

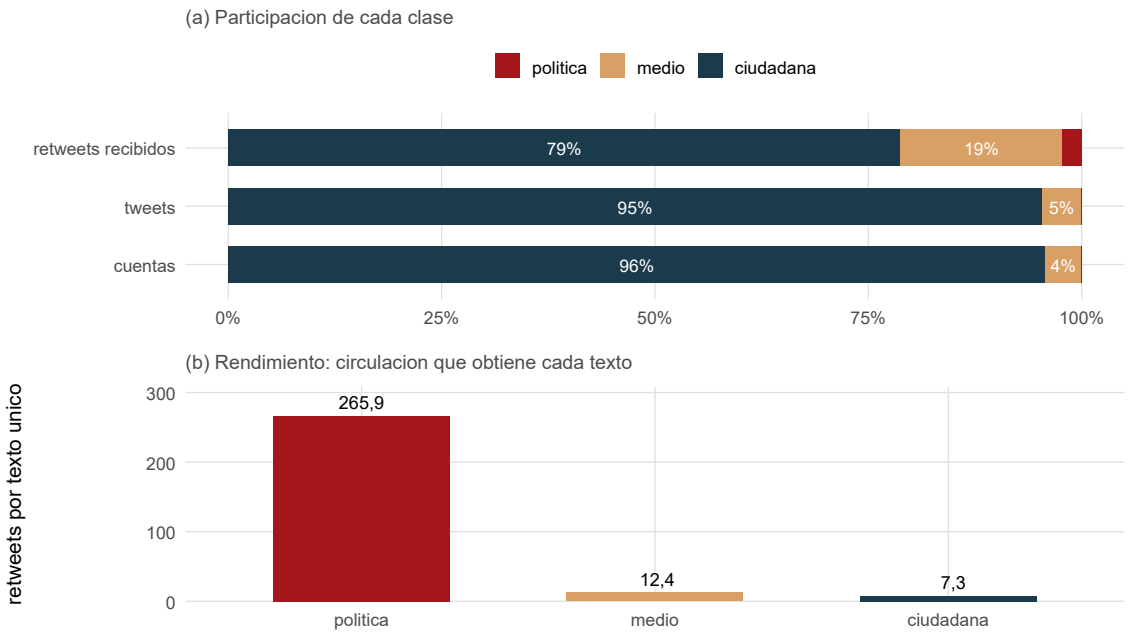


Figura 4: Clases de cuenta. (a) Participación de cada clase en cuentas, publicaciones y retweets recibidos. (b) Circulación obtenida por cada texto único.

6. Limitaciones

1. **Bordes truncados.** El 11 y el 29 de octubre contienen 168 y 4.203 publicaciones respectivamente, por el corte de la ventana de recolección. Deben excluirse de cualquier serie diaria.
2. **Sesgo hacia el vocabulario inicial.** La lista de consultas se fijó durante la primera semana. El 25 de octubre, día de la mayor manifestación del ciclo, registra 112.812 publicaciones, menos que la víspera. La consulta `#MarchaDelMillon` aporta 48.558 publicaciones frente a las 603.398 de `#ChileDesperto`. El corpus subrepresenta sistemáticamente la segunda semana.
3. **Contaminación por consulta ambigua.** Cuantificada en la
    1. Se recomienda excluir las comunidades 1, 2 y 8 de todo análisis sustantivo sobre el estallido.
4. **La clase *medio* es heurística.** A diferencia de la clase política, que procede de un registro, se detecta por vocabulario y presenta errores en ambas direcciones. Debe usarse como filtro y no como censo.
5. **Perfil léxico de la clase política no interpretable.** Con 451 textos únicos, las medidas de especificidad quedan dominadas por un puñado de publicaciones virales.
6. **Cobertura incompleta del padrón.** Se identifican 135 de 156 diputados en ejercicio (86,5 %) y 6 de 16 ministros.

7. Declaración ética

El corpus contiene publicaciones que eran públicas al momento de su emisión. Se aplica seudonimización diferenciada: las cuentas de cargos públicos conservan su identificador, por tratarse de actuación pública de figuras públicas y porque su trazabilidad es condición del valor analítico; las restantes se sustituyen por un resumen criptográfico estable con sal. La antigüedad de cuenta se publica en años y el número de seguidores en órdenes de magnitud, pues su combinación exacta permite la reidentificación.

Se reconoce una tensión irresoluble: el valor archivístico del corpus proviene de preservar material que ya no existe en la plataforma, y esa misma propiedad constituye el problema de privacidad, en particular respecto de usuarios que eliminaron sus cuentas con posterioridad. La distinción por condición de figura pública administra esa tensión sin eliminarla.

La redistribución se ajusta a las restricciones de la plataforma, que limitan la difusión de contenido a identificadores (Golland et al. 2026). Se publican abiertamente los identificadores y los derivados que no constituyen contenido; el texto de cuentas ciudadanas queda disponible bajo solicitud.

8. Disponibilidad de los datos

Código y datos derivados: `https://github.com/Alcatruz/estallido-twitter-2019`. Depósito con identificador persistente en preparación.

Agradecimientos

El procesamiento utilizó `data.table` (Dowle y Srinivasan 2023), `igraph` (Csardi y Nepusz 2006) y `arrow`.

Csardi, Gabor, y Tamas Nepusz. 2006. «The igraph software package for complex network research». *InterJournal, Complex Systems* 1695 (5): 1-9.

Dowle, Matt, y Arun Srinivasan. 2023. *data.table: Extension of 'data.frame'*.

Golland, Alexander, Oliver Watteler, Jonas Recker, Jan Schwalbach, y Libby Bishop. 2026. «From (almost) open to heavily restricted data access: The development of the Twitter/X developer policies». *Big Data & Society*. https://doi.org/10.1177/20539517261419333.

«Nonrandom Tweet Mortality and Data Access Restrictions: Compromising the Replication of Sensitive Twitter Studies». 2024. *Political Analysis*.

Traag, Vincent A., Ludo Waltman, y Nees Jan van Eck. 2019. «From Louvain to Leiden: guaranteeing well-connected communities». *Scientific Reports* 9 (1): 5233. https://doi.org/10.1038/s41598-019-41695-z.